AssociationRuleMarketBasket

December 31, 2018

El Mostafa Hariss et Timothée Papin

0.1 Import des données

Dans le cadre du projet sur l'apprentissage non-supervisé, nous avons choisi un sujet sur les règles d'association lors des paniers d'achats. L'objectif sera de trouver des clusters de paniers d'achats pour pouvoir faire des liens entre des produits. Nous présenterons trois méthodes: - Analyse en Composante Principale - K-Means - Approche hierarchiques - Apriori et règle d'association avec la librairie Mlxtend

In [1]:
```
%matplotlib inline
import os
import pandas as pd
import numpy as np
from mlxtend.preprocessing import TransactionEncoder
```

In [6]:
```
# Import des données csv
df0 = pd.read_csv('groceries.csv',header=None).fillna('Na')
df0.loc[:,0:4].head(n=5)
```

Out[6]:

	0	1	2	3	4
0	citrus fruit	semi-finished bread	margarine	ready soups	Na
1	tropical fruit	yogurt	coffee	Na	Na
2	whole milk	Na	Na	Na	Na
3	pip fruit	yogurt	cream cheese	meat spreads	Na
4	other vegetables	whole milk	condensed milk	long life bakery product	Na

In [7]:
```
# Transformation des variables catégorielles (produits) en variables binaires pour chaqu
dataset = df0.values.tolist()
te = TransactionEncoder()
te_ary = te.fit(dataset).transform(dataset).astype("int")
df = pd.DataFrame(te_ary, columns=te.columns_)
df = df.drop(columns="Na")
```

0.2 PCA model

```
In [8]: from sklearn.decomposition import PCA
        x = df.values
        pca = PCA()
        pca.fit(x)
```

```
Out[8]: PCA(copy=True, iterated_power='auto', n_components=None, random_state=None,
          svd_solver='auto', tol=0.0, whiten=False)
```

Représentation des listes d'achat sur les 8 premières composantes

```
In [31]: import matplotlib.pyplot as plt
         x_pca = pca.transform(x)

         fig = plt.figure(figsize=(5,5))
         ax0 = fig.add_subplot(331)

         ax1 = fig.add_subplot(332)
         ax1.scatter(x_pca[:, 0], x_pca[:, 1])
         ax1.set_title('PC1 vs PC2')

         ax2 = fig.add_subplot(333)
         ax2.scatter(x_pca[:, 0], x_pca[:, 2])
         ax2.set_title('PC1 vs PC3')

         ax3 = fig.add_subplot(334)
         ax3.scatter(x_pca[:, 1], x_pca[:, 0])
         ax3.set_title('PC2 vs PC1')

         ax4 = fig.add_subplot(335)

         ax5 = fig.add_subplot(336)
         ax5.scatter(x_pca[:, 1], x_pca[:, 2])
         ax5.set_title('PC2 vs PC3')

         ax6 = fig.add_subplot(337)
         ax6.scatter(x_pca[:, 2], x_pca[:, 0])
         ax6.set_title('PC3 vs PC1')

         ax7 = fig.add_subplot(338)
         ax7.scatter(x_pca[:, 2], x_pca[:, 1])
         ax7.set_title('PC3 vs PC2')

         ax8 = fig.add_subplot(339)
```

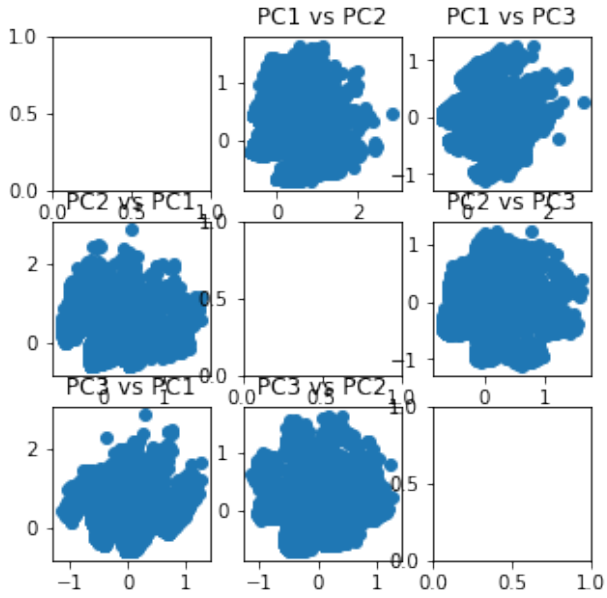

On apercoit des clusters sur les axes 1 et 3 ainsi que 2 et 3. Nous allons regarder quelle est la variance expliquer par les premières composantes.

```
In [32]: plt.figure(figsize=(5,5))
         plt.plot(np.cumsum(pca.explained_variance_ratio_))
         plt.xlabel('Nombre de composantes')
         plt.ylabel('Variance cumulée');
```

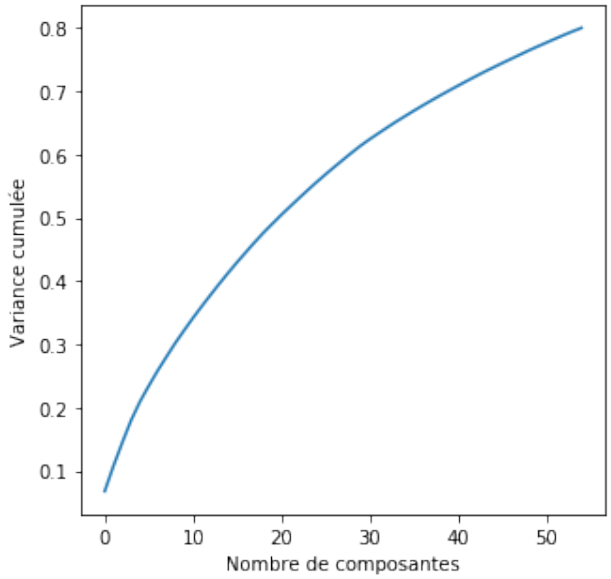

Les 55 premières composantes n'expliquent que 80% de la variance et les 80 premières n'expliquent que 90%.

```
In [33]: PCs = pca.components_
         plt.figure(figsize=(5,5))
         plt.quiver(np.zeros(PCs.shape[1]), np.zeros(PCs.shape[1]),
                    PCs[0,:], PCs[1,:],
                    angles='xy', scale_units='xy', scale=1)

         # Ajout des labels
         for i,j,z in zip(PCs[1,:]+0.02, PCs[0,:]+0.02, df.columns):
             if i*i+j*j>0.05:
                 plt.text(j, i, z, ha='center', va='center')

         plt.axis('equal')
         plt.xlim([-1.0,1.0])
         plt.ylim([-1.0,1.0])

         # Label axes
         plt.xlabel('PC 0')
         plt.ylabel('PC 1')
         plt.title("Représentation de chaque produit sur les 2 premières composantes")

Out[33]: Text(0.5,1,'Représentation de chaque produit sur les 2 premières composantes')
```

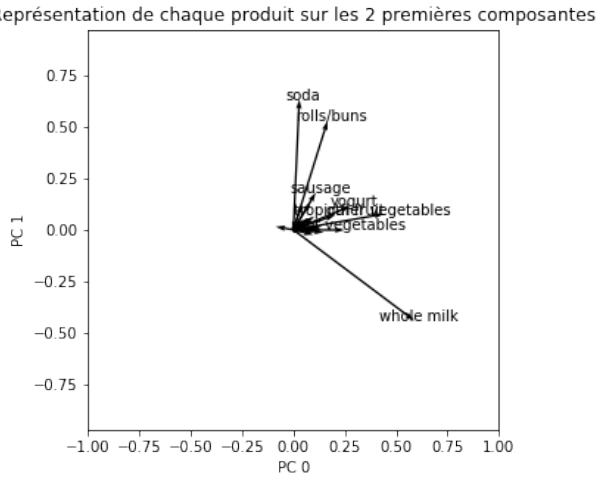

On constate un lien entre les légumes, les fruits et les yaourts. Ainsi qu'un lien entre le soda et les rolls/buns. On voit aussi que le lait est très décorrélé des autres achats.

0.3 K-Means

L'approche K-means est peu performante pour les dimensions élevées. Etant donnée que nous avons déjà fait une PCA, nous allons donc réduire le nombre de variable à 55.

Nous avons essayé plusieurs nombres de clusters pour observer la stabilité des résultats et leurs pertinence. Nous nous sommes aussi basé sur les résultats de l'approche hierarchique que nous verrons un peu plus loin.

In [34]:
```
from sklearn.cluster import KMeans
from mpl_toolkits.mplot3d import Axes3D

# L'approche K-means est peu performante pour les dimensions élevées,
# nous allons donc réduire le nombre de variable avec la PCA.
pca = PCA(n_components=55)
pca.fit(x)
x = pca.transform(x)

n_clusters = 5
km = KMeans(n_clusters=n_clusters)

fig = plt.figure(figsize=(5, 5))
ax = Axes3D(fig)
km.fit(x)
labels_km = km.labels_
ax.scatter(x[:, 3], x[:, 0], x[:, 2],c=labels_km.astype(np.float), edgecolor='k')
```

Out[34]: `<mpl_toolkits.mplot3d.art3d.Path3DCollection at 0x2395c505668>`

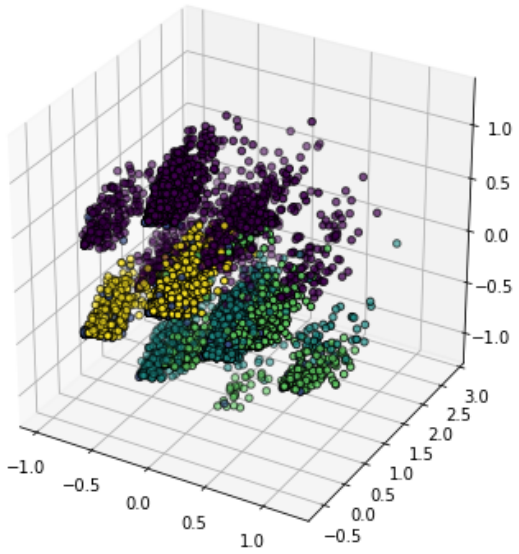

0.3.1 Top 10 des produits les plus achetés

In [13]:
```
df.sum().sort_values(ascending=False).nlargest(10)
```

```
Out[13]: whole milk          2513
         other vegetables    1903
         rolls/buns          1809
         soda                1715
         yogurt              1372
         bottled water       1087
         root vegetables     1072
         tropical fruit      1032
         shopping bags        969
         sausage              924
         dtype: int64
```

0.3.2 Top 10 des produits les plus achetés par cluster

```
In [14]: for i in range (1,n_clusters+1):
             print('\n Top 10 des produits les plus achetés dans le cluster ' + str(i))
             print(df.loc[np.where(labels_km==i-1)].sum().sort_values(ascending=False).nlargest(
```

```
 Top 10 des produits les plus achetés dans le cluster 1
whole milk         1289
rolls/buns          266
root vegetables     182
tropical fruit      156
bottled water       142
dtype: int64

 Top 10 des produits les plus achetés dans le cluster 2
soda              1318
rolls/buns         262
bottled water      206
shopping bags      181
whole milk         156
dtype: int64

 Top 10 des produits les plus achetés dans le cluster 3
other vegetables    1406
whole milk           517
root vegetables      340
rolls/buns           288
tropical fruit       228
dtype: int64

 Top 10 des produits les plus achetés dans le cluster 4
rolls/buns       681
canned beer      513
shopping bags    382
bottled beer     379
```

```
bottled water    379
dtype: int64

 Top 10 des produits les plus achetés dans le cluster 5
yogurt              1289
whole milk           551
other vegetables     426
rolls/buns           312
tropical fruit       278
dtype: int64
```

Dans le cas de 5 clusters, nous observons que: - cluster 1: paniers ayant essentiellement du lait - cluster 2: paniers ayant essentiellement des sodas - cluster 3: paniers ayant du lait, légupes et fruits - cluster 4: paniers ayant des rolls, bieres, eaux et des sac (surement pour les bouteilles) - cluster 5: paniers ayant des yaourts, lait et légumes

On peut conclure que les sodas, les bieres et les légumes/fruits sont achetés séparément. Ceci est cohérent au vue des résultats eu avec la PCA.

0.3.3 Agglomerative Clustering

```
In [20]: import scipy.cluster.hierarchy as sch
         from sklearn.cluster import AgglomerativeClustering

In [35]: x = df.values #x_pca
         plt.figure(figsize=(5, 5))
         dendrogram = sch.dendrogram(sch.linkage(x, method='ward'),truncate_mode='level',p=5)
```

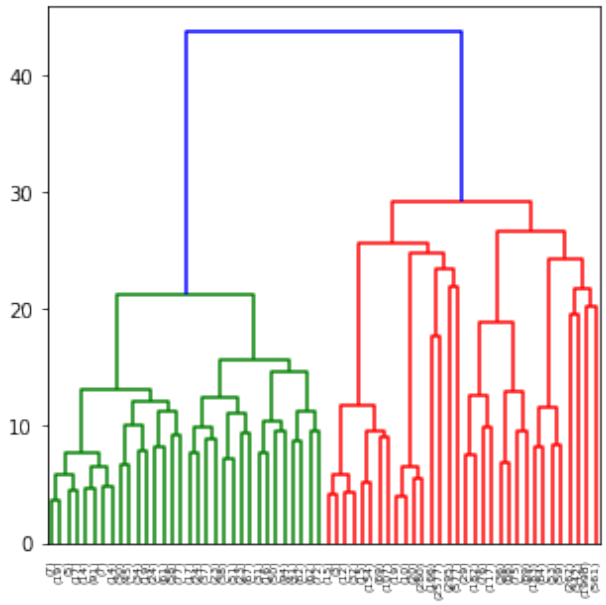

Le dendogramme nous permet de choisir le nombre de cluster en fonction de la distance. Pour faciliter l'affichage, nous n'avons représenté que les 5 premiers niveaux. On se rend compte que le nombre de clusters augmentent très vite d'où notre souhait de limiter le nombre de clusters à 5.

```
In [25]: #n_clusters = 5
         ac = AgglomerativeClustering(n_clusters=n_clusters, affinity = 'euclidean', linkage = '
         labels_ac = ac.fit_predict(x)

In [26]: for i in range (1,n_clusters+1):
             print('\n Top 10 des produits les plus achetés dans le cluster ' + str(i))
             print(df.loc[np.where(labels_ac==i-1)].sum().sort_values(ascending=False).nlargest(
```

```
 Top 10 des produits les plus achetés dans le cluster 1
soda              813
canned beer       550
bottled water     467
whole milk        442
rolls/buns        418
dtype: int64

 Top 10 des produits les plus achetés dans le cluster 2
other vegetables    962
whole milk          632
yogurt              420
root vegetables     416
rolls/buns          325
dtype: int64

 Top 10 des produits les plus achetés dans le cluster 3
whole milk          1179
yogurt               721
other vegetables     602
tropical fruit       535
root vegetables      489
dtype: int64

 Top 10 des produits les plus achetés dans le cluster 4
rolls/buns        546
sausage           244
whole milk        205
soda              160
shopping bags     125
dtype: int64

 Top 10 des produits les plus achetés dans le cluster 5
bottled beer     378
bottled water     72
```

```
soda              70
liquor            63
whole milk        55
dtype: int64
```

Dans le cas de 5 clusters, nous observons que: - cluster 1 et 5: paniers ayant des boissons (sodas, bieres, eau et lait) - cluster 2: paniers ayant des légumes, lait et yaourt - cluster 3: paniers ayant des légumes, lait et yaourt plus des fruits - cluster 4: paniers diversifiés (rolls, sausage, lait et soda)

On peut conclure que les boissons et les légumes/fruits sont achetés séparément ce qui est proche de ce que l'on a observé avec les K-Means.

0.3.4 Comparaison K-means et AC

```
In [27]: from sklearn.metrics import confusion_matrix
         mat = confusion_matrix(labels_ac,labels_km)

         plt.matshow(mat, cmap=plt.cm.gray_r) # imshow
         plt.colorbar()

         plt.xlabel('K-Means clusters')
         plt.ylabel('Agglomerative clustering')

Out[27]: Text(0,0.5,'Agglomerative clustering')
```

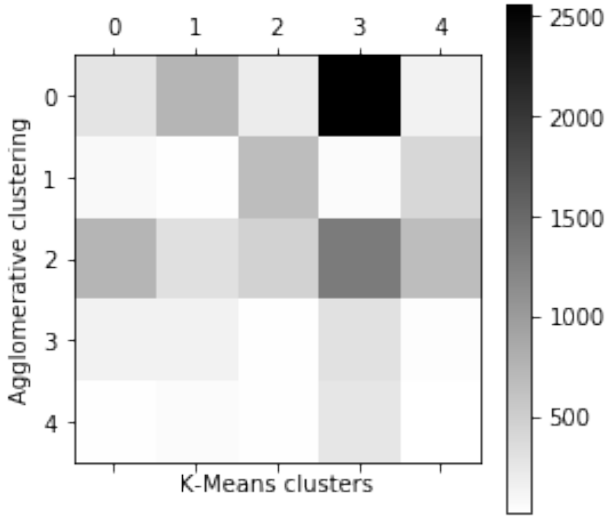

On obtient une certaine concordance entre les clusters obtenues par les 2 méthodes: - cluster KM 1 <=> cluster AC 3 (cluster des lait, yaourt, légumes et fruit) - cluster KM 2 <=> cluster AC 1 (cluster des boissons) - cluster KM 3 <=> cluster AC 2 (cluster légumes et lait) - cluster KM 4 <=>

cluster AC 1 (cluster boissons) - cluster KM 5 <=> cluster AC 3 (cluster des lait, yaourt, légumes et fruit)

Les approches K-Means et Hierarchique mettent en évidence que les boissons et les légumes/fruits sont achetés séparément.

0.4 Pour aller un peu plus loin

La librairie Mlxtend permet de résoudre des problématiques d'apriori et d'association.

```
In [36]: from mlxtend.frequent_patterns import apriori
         frequent_itemsets = apriori(df, min_support=0.05, use_colnames=True)
         frequent_itemsets['length'] = frequent_itemsets['itemsets'].apply(lambda x: len(x))
         frequent_itemsets[ (frequent_itemsets['length'] == 2)]
```

```
Out[36]:      support                         itemsets  length
         28  0.074835  (whole milk, other vegetables)       2
         29  0.056634        (rolls/buns, whole milk)       2
         30  0.056024            (yogurt, whole milk)       2
```

La fonction d'apriori nous renvoie les aliments ayant une occurence d'au moins 5%. Seulement 3 couples d'aliments apparaissent dans le top 30: - lait et légumes - lait et rolls/buns - lait et yaourt

```
In [30]: from mlxtend.frequent_patterns import association_rules
         association_rules(frequent_itemsets, metric="confidence", min_threshold=0.2)
```

```
Out[30]:           antecedents         consequents  antecedent support  \
         0        (whole milk)  (other vegetables)            0.255516
         1  (other vegetables)        (whole milk)            0.193493
         2        (rolls/buns)        (whole milk)            0.183935
         3        (whole milk)        (rolls/buns)            0.255516
         4            (yogurt)        (whole milk)            0.139502
         5        (whole milk)            (yogurt)            0.255516

            consequent support   support  confidence      lift  leverage  conviction
         0            0.193493  0.074835    0.292877  1.513634  0.025394    1.140548
         1            0.255516  0.074835    0.386758  1.513634  0.025394    1.214013
         2            0.255516  0.056634    0.307905  1.205032  0.009636    1.075696
         3            0.183935  0.056634    0.221647  1.205032  0.009636    1.048452
         4            0.255516  0.056024    0.401603  1.571735  0.020379    1.244132
         5            0.139502  0.056024    0.219260  1.571735  0.020379    1.102157
```

En définissant un threshold à 20% sur l'indice de confiance (confidence), nous obtenons 5 associations. Les 5 associations sont cohérentes avec les clusters établis précédemment.